Autor: Iván García Santillán

Semana (1)

Preparando y entendiendo los datos para la Predicción del cáncer de mama

Objetivo y alcance del trabajo

Esta práctica tiene el objetivo de realizar un preprocesamiento de datos y un Análisis exploratorio de datos (estadísticas y visualización) de las variables más relevantes que considere para el propósito de predicción de cáncer de mama. Al finalizar la práctica, los maestrantes podrán manipular adecuadamente un dataset de datos estructurados (alfanuméricos).

Explicación del Trabajo

Utilice el dataset de cáncer de mama (Diagnostic Wisconsin Breast Cancer Database, WBCD) donde tenemos los datos de 569 mujeres. Cada mujer está descrita por 32 atributos. El primero es un identificador, el segundo el tipo de cáncer (Maligno o Benigno) y el resto son el resultado de otros análisis clínicos. Se pretende aprender el tipo de cáncer de mama (maligno=1, benigno=0). En este conjunto de datos la distribución de clases es: 357 benignos y 212 malignos.

Fase I

Se pide al maestrante realizar las siguientes actividades:

- Descargue el dataset:
 http://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagn-ostic
- Cargue el conjunto de datos en el entorno de Python
- Realizar el preprocesamiento de datos:
 - Sustituir las M's por 1 y las B's por 0.
 - Descarte la primera columna (el identificador) ya que no aporta nada al problema:
 - o Verifique valores perdidos.

Fase II

Se pide al maestrante realizar las siguientes actividades:

- Realizar un Análisis exploratorio de datos (estadísticas y visualización) de las variables más relevantes que considere para el propósito de predicción de cáncer de mama.
- Interprete los resultados obtenidos en un informe conciso en Word o en dentro del mismo notebook de Python.
- Suba el notebook de Python y/o el informe Word al LMS (plataforma).

ANEXOS

Rúbrica de Evaluación de la práctica

Rúbrica de calificación de la práctica:

Criterio	Excelente	Bueno	Aceptable	Bajo
Análisis	El análisis exploratorio de	El análisis exploratorio de	El análisis exploratorio de	El análisis exploratorio de
exploratorio de	datos es relevante, detallado	datos es adecuado para la	datos es adecuado para la	datos no es adecuado para la
datos	y adecuado para la	comprensión de los datos y	comprensión de los datos y	comprensión de los datos y
	comprensión de los datos y	el negocio incluyendo un	el negocio, pero podría	el negocio y debe mejorarse
	el negocio incluyendo un	preprocesamiento de	mejorarse en la variedad	significativamente.
	preprocesamiento de datos,	datos, estadísticas y	de técnicas, estadísticas y	
	estadísticas y visualización	visualización de datos.	visualizaciones.	
	de datos.			
Elaboración de	El informe presentado es	El informe presentado es	El informe presentado es	El informe presentado no es
informe / notebook	relevante, claro y conciso	adecuado y conciso	adecuado incluyendo	adecuado, faltando
	incluyendo todas las	incluyendo varias	algunas estadísticas y	estadísticas y
	estadísticas y	estadísticas y	visualizaciones de datos,	visualizaciones de datos.
	visualizaciones de datos.	visualizaciones de datos.	pero podría	
			complementarse con otras.	
Presentación del	La presentación del caso	La presentación del caso	La presentación del caso	La presentación del caso
caso práctico	práctico es clara, completa y	práctico es clara y concisa	práctico es clara utilizando	práctico no es clara, no
	concisa utilizando material	utilizando material visual	material visual en el	utiliza material visual
	visual en el tiempo asignado	en el tiempo asignado.	tiempo asignado, pero	adecuado y no respeta el
	demostrando un alto nivel		podría profundizarse en	tiempo asignado.
	de creatividad.		aspectos relevantes.	